




V19 -1.1



Minimalna vrijednost je 0 što postizemo kad  $K = \text{br. promjera}$   
(svaki promjer postaje centroid svoj grupe pa je euklidita udaljenost od centroida 0)




$$\Rightarrow \bar{g}_{K=2} > \bar{g}_{K=4} > \bar{g}_{K=6}$$



Za K-means ++, zbog načina odabira centroida, vjerojatnije su da će se  
sve grupe više  $\bar{g}$  kad konvergiraju  
te one koje konvergiraju brže.

V19 -1.2



	$M_1$	$M_2$	$M_3$
a)	b	c	e
a	19	$\sqrt{20}$	$\sqrt{45}$
d	12	$\sqrt{20}$	$\sqrt{32}$
f	$\sqrt{41}$	$\sqrt{29}$	15
g	$\sqrt{52}$	11	$\sqrt{20}$



$$M_1 = (6, 1.66) \text{ (aritmetički sred od a, d, b)}$$

$$M_2 = (0.5, 5) \text{ (-11- c, g)}$$

$$M_3 = (2.5, 4) \text{ (-11- e, f)}$$

b)

$K_1$	$K_2$	$K_3$
(d, f, g)	b	f

Matrica udaljenosti (euklidskih) jer ne može biti ista udaljenost u klasi

	a	b	c	d	e	f	g
a	0	5	20	1	15	20	29
b	5	0	45	2	74	41	58
c	20	45	0	20	17	8	4
d	1	2	20	0	52	15	40
e	15	74	17	52	0	5	20
f	20	41	8	15	5	0	13
g	29	58	4	40	20	13	0

novi medijeti  
su  
d za  $K_1$   
f za  $K_3$   
g za  $K_2$



V13 - 1.2 NASTAVAK <sup>u. značajni</sup>

c) K-Means -  $O(TnNK)$

K-Medoid -  $O(TK(N-K)^2)$

T je k. iteracija

$O(K\text{-Medoid})$  je kvadratno složenosti, dok je  $O(K\text{-Means})$  linearna u broju primjera

PROS: podatci ne moraju biti vektori  
možemo u različite mjere udaljenosti (računati)

CONS: velika složenost

## V20 - 1.1

a) EM koristi metodu grupiranja  $\rightarrow$  probabilistički izbor te primjer može pripadati više grupa  $\rightarrow$  moguće računati potpunu log-izglednost.

Nedostatak je značajnu veću složenost.

$$b) p(x) = \sum_{k=1}^K p(x, y=z_k) = \sum_{k=1}^K p(y=z_k) p(x|y=z_k) = \sum_{k=1}^K \pi_k p(x|\theta_k)$$

$$\ln(L(\theta|x)) = \ln \prod_{i=1}^N p(x^i) = \ln \prod_{i=1}^N \sum_{k=1}^K \pi_k p(x^i|\theta_k) = \sum_{i=1}^N \ln \sum_{k=1}^K \pi_k p(x^i|\theta_k)$$

$$c) p(x, z|\theta) = p(z) p(x|z, \theta) = \prod_{i=1}^N \pi_{z_i} \prod_{k=1}^K p(x^i|\theta_k)^{z_k} = \prod_{i=1}^N \pi_{z_i}^{z_k} p(x^i|\theta_k)^{z_k}$$

$$\begin{aligned} \ln(L(\theta|x, z)) &= \ln \prod_{i=1}^N p(x^i, z^i|\theta) = \ln \prod_{i=1}^N \prod_{k=1}^K \pi_k^{z_k^i} p(x^i|\theta_k)^{z_k^i} \\ &= \sum_{i=1}^N \sum_{k=1}^K z_k^i (\ln \pi_k + \ln p(x^i|\theta_k)) \end{aligned}$$

Kad bi znali  $z^i$ -jeve mogli bi analitički maksimizirati log izglednost. Kako to ne znamo, moramo fiksirati  $\pi_k$  i  $\theta_k$  za računanje očekivanja izglednosti.

d) E: računanje potpune log izglednosti uz fiksne parametre u iteraciji t

$$\begin{aligned} Q(\theta|\theta^{(t)}) &= \mathbb{E}_{z|x, \theta^{(t)}} \left[ \sum_{i=1}^N \sum_{k=1}^K z_k^i (\ln \pi_k + \ln p(x^i|\theta_k)) \right] \\ &= \sum_{i=1}^N \sum_{k=1}^K \underbrace{\mathbb{E}[z_k^i|x, \theta^{(t)}]}_{h_k^i} (\ln(\pi_k) + \ln p(x^i|\theta_k)) \end{aligned}$$



V20-1.1 DASTAVAK

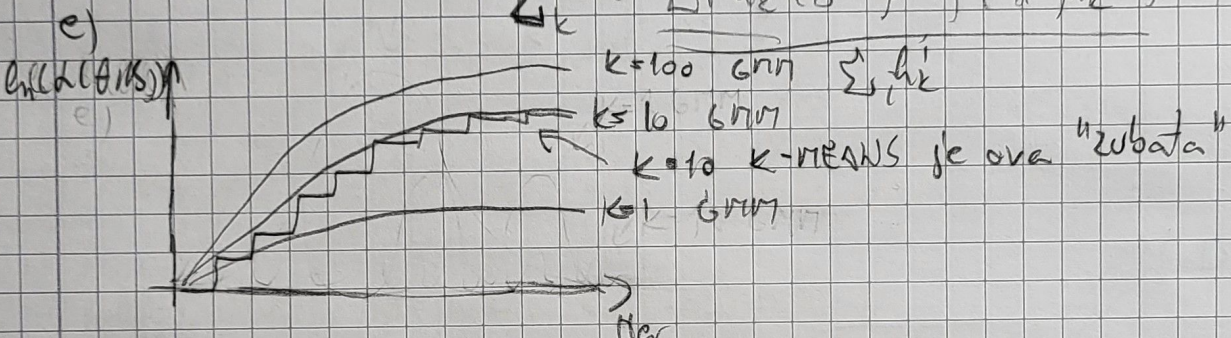
d) M-Sokal - izračun parametara 2. iteracije  $t+1$  naj manjim zračni očuvanje.

$$\nabla_{\theta} Q(\theta, \theta^t) = 0$$


$$\nabla_{\mu_k} \left( \sum_{i=1}^N \sum_{k=1}^K h_k^i \ln \pi_k + \lambda \left( \sum_{k=1}^K \pi_k - 1 \right) \right) = 0 \Rightarrow \pi_k^{t+1} = \frac{1}{N} \sum_{i=1}^N h_k^i$$

$$\nabla_{\theta_k} \sum_{i=1}^N h_k^i \ln(p(\delta^i | \theta_k)) = 0 \Rightarrow \mu_k^{t+1} = \frac{\sum_{i=1}^N h_k^i \delta^i}{\sum_{i=1}^N h_k^i}$$


$$\sum_k \mu_k^{t+1} = \frac{\sum_k \sum_{i=1}^N h_k^i \delta^i}{\sum_k \sum_{i=1}^N h_k^i} = \frac{\sum_{i=1}^N \delta^i}{\sum_{i=1}^N 1} = \bar{x}$$



V20-1.2



Ali gledamo da želimo izći gdje su promjeni prirodno grupirani i grane dugačke, rekla bi da izićemo nakon grupiranja "c" i "e".



I ovako je najdulja grana između "c" i "e" na ovoj izićemo na atom.

V21-1.1

Y	X	p	Q	R	S	T
1	1	0	1	1	1	1
0	2	1	1	1	1	1
2	2	1	1	1	1	1
1	2	1	1	1	1	1
1	1	1	1	1	1	1
0	0	1	1	1	1	1
1	1	1	1	1	1	1
2	1	1	1	1	1	1
0	1	1	1	1	1	1
2	0	1	1	1	1	1
2	1	1	1	1	1	1

Micro: Acc = 21/33  
 Pr = 5/11  
 R = 5/11  
 F1 =  $\frac{2}{\frac{1}{5} + \frac{1}{5}} = \frac{5}{2}$

Macro: Acc =  $\frac{8/11 + 7/11 + 6/11}{3} = \frac{21}{33}$   
 Pr =  $\frac{4}{9}$   
 R =  $\frac{4}{9}$   
 F1 =  $\frac{4}{9}$